

Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ **ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ**

КАФЕДРА **ИНФОРМАЦИОННЫЕ СИСТЕМЫ И ТЕЛЕКОММУНИКАЦИИ (ИУ3)**

НАПРАВЛЕНИЕ ПОДГОТОВКИ **09.03.03 ПРИКЛАДНАЯ ИНФОРМАТИКА**

ОТЧЕТ

по лабораторной работе № 1

Название: Разведочный анализ данных. Исследование и визуализация данных

Дисциплина: Технологии машинного обучения

Студент ИУ3С-51Б (Группа) _____ (Подпись, дата) М.Ю. Гордон (И.О. Фамилия)

Преподаватель _____ (Подпись, дата) О.Г. Саргсян (И.О. Фамилия)

Москва, 2026

1. Описание задания

Цель лабораторной работы - изучить методы разведочного анализа данных и их визуализации с использованием языка программирования Python.

В ходе работы необходимо выбрать набор данных, изучить его основные характеристики, исследовать распределение признаков с помощью графиков и определить взаимосвязи между числовыми признаками с использованием корреляционного анализа.

Для выполнения работы выбран набор данных Iris, содержащий информацию о трех видах ирисов. В процессе исследования выполнена проверка структуры данных, типов столбцов и наличия пропущенных значений, построены графики распределения и взаимосвязи признаков, а также корреляционная матрица и тепловая карта корреляций.

2. Текст программы

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.datasets import load_iris


# Загрузка датасета
iris = load_iris()

# Создание DataFrame
df = pd.DataFrame(
    iris.data,
    columns=iris.feature_names
)

# Добавляем целевую переменную
df["target"] = iris.target

# Добавляем название вида ириса
```

```
df["species"] = df["target"].map({
    0: "setosa",
    1: "versicolor",
    2: "virginica"
})


print("Датасет Iris")
print()

print("Первые 5 строк:")
print(df.head())

print()
print("Размер датасета:")
print(df.shape)

print()
print("Типы данных:")
print(df.dtypes)

print()
print("Количество пропусков:")
print(df.isnull().sum())

print()
print("Статистические характеристики:")
print(df.describe())

# Гистограммы распределения признаков

df.hist(
    figsize=(12, 8),
    bins=15
)

plt.suptitle("Распределение признаков датасета Iris")
plt.tight_layout()

plt.savefig("result/histograms.png")
plt.show()
```

```
# Диаграмма рассеяния:
# длина чашелистика и длина лепестка

plt.figure(figsize=(10, 6))

sns.scatterplot(
    data=df,
    x="sepal length (cm)",
    y="petal length (cm)",
    hue="species"
)

plt.title("Зависимость длины лепестка от длины чашелистика")
plt.xlabel("Длина чашелистика (см)")
plt.ylabel("Длина лепестка (см)")

plt.tight_layout()
plt.savefig("result/scatter_sepal_petal.png")
plt.show()

# Диаграмма рассеяния:
# длина лепестка и ширина лепестка

plt.figure(figsize=(10, 6))

sns.scatterplot(
    data=df,
    x="petal length (cm)",
    y="petal width (cm)",
    hue="species"
)

plt.title("Зависимость ширины лепестка от его длины")
plt.xlabel("Длина лепестка (см)")
plt.ylabel("Ширина лепестка (см)")

plt.tight_layout()
plt.savefig("result/scatter_petal.png")
plt.show()

# Ящик с усами для сравнения длины лепестка
```

```
plt.figure(figsize=(10, 6))

sns.boxplot(
    data=df,
    x="species",
    y="petal length (cm)"
)

plt.title("Распределение длины лепестка по видам ириса")
plt.xlabel("Вид ириса")
plt.ylabel("Длина лепестка (см)")

plt.tight_layout()
plt.savefig("result/boxplot_petal_length.png")
plt.show()

# Корреляция признаков

# Выбираем только числовые признаки
numeric_df = df[
    [
        "sepal length (cm)",
        "sepal width (cm)",
        "petal length (cm)",
        "petal width (cm)"
    ]
]

# Вычисляем корреляционную матрицу
correlation_matrix = numeric_df.corr()

print()
print("Корреляционная матрица:")
print(correlation_matrix)

# Тепловая карта корреляций

plt.figure(figsize=(10, 8))

sns.heatmap(
    correlation_matrix,
    annot=True,
```

```
    cmap="coolwarm",
    fmt=".2f"
)

plt.title("Корреляция признаков датасета Iris")

plt.tight_layout()
plt.savefig("result/correlation_heatmap.png")
plt.show()
```

3. Скриншоты выполнения программы

В результате выполнения программы были получены следующие результаты разведочного анализа и визуализации набора данных Iris.

```
Датасет Iris

Первые 5 строк:
   sepal length (cm)  sepal width (cm)  ...  target  species
0                5.1               3.5  ...       0   setosa
1                4.9               3.0  ...       0   setosa
2                4.7               3.2  ...       0   setosa
3                4.6               3.1  ...       0   setosa
4                5.0               3.6  ...       0   setosa

[5 rows x 6 columns]

Размер датасета:
(150, 6)

Типы данных:
sepal length (cm)    float64
sepal width (cm)     float64
petal length (cm)    float64
petal width (cm)     float64
target                 int64
species                  str
dtype: object
```

```
Количество пропусков:
sepal length (cm)    0
sepal width (cm)     0
petal length (cm)    0
petal width (cm)     0
target               0
species              0
dtype: int64

Статистические характеристики:
       sepal length (cm)  sepal width (cm)  ...  petal width (cm)      target
count         150.000000        150.000000  ...        150.000000  150.000000
mean            5.843333          3.057333  ...          1.199333    1.000000
std             0.828066          0.435866  ...          0.762238    0.819232
min             4.300000          2.000000  ...          0.100000    0.000000
25%             5.100000          2.800000  ...          0.300000    0.000000
50%             5.800000          3.000000  ...          1.300000    1.000000
75%             6.400000          3.300000  ...          1.800000    2.000000
max             7.900000          4.400000  ...          2.500000    2.000000

[8 rows x 5 columns]
```

Рисунок 1 - Результаты первичного анализа набора данных Iris

На рисунке представлены результаты первичного анализа набора данных. Набор содержит 150 объектов и 6 столбцов. Пропущенные значения отсутствуют. Для числовых признаков приведены основные статистические характеристики.

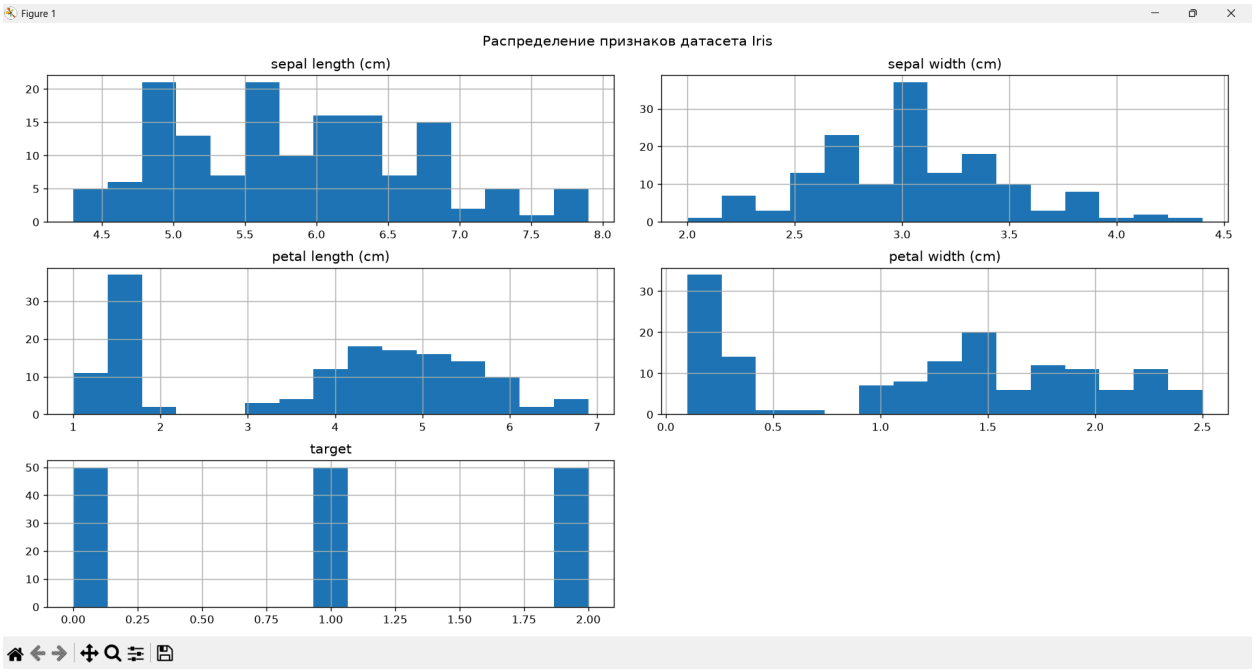


Рисунок 2 - Распределение признаков датасета Iris

На гистограммах показано распределение значений основных числовых признаков набора данных. Видно, в каких диапазонах находятся значения длины и ширины чашелистика и лепестка. Гистограммы позволяют сравнить распределение признаков и увидеть их основные диапазоны.

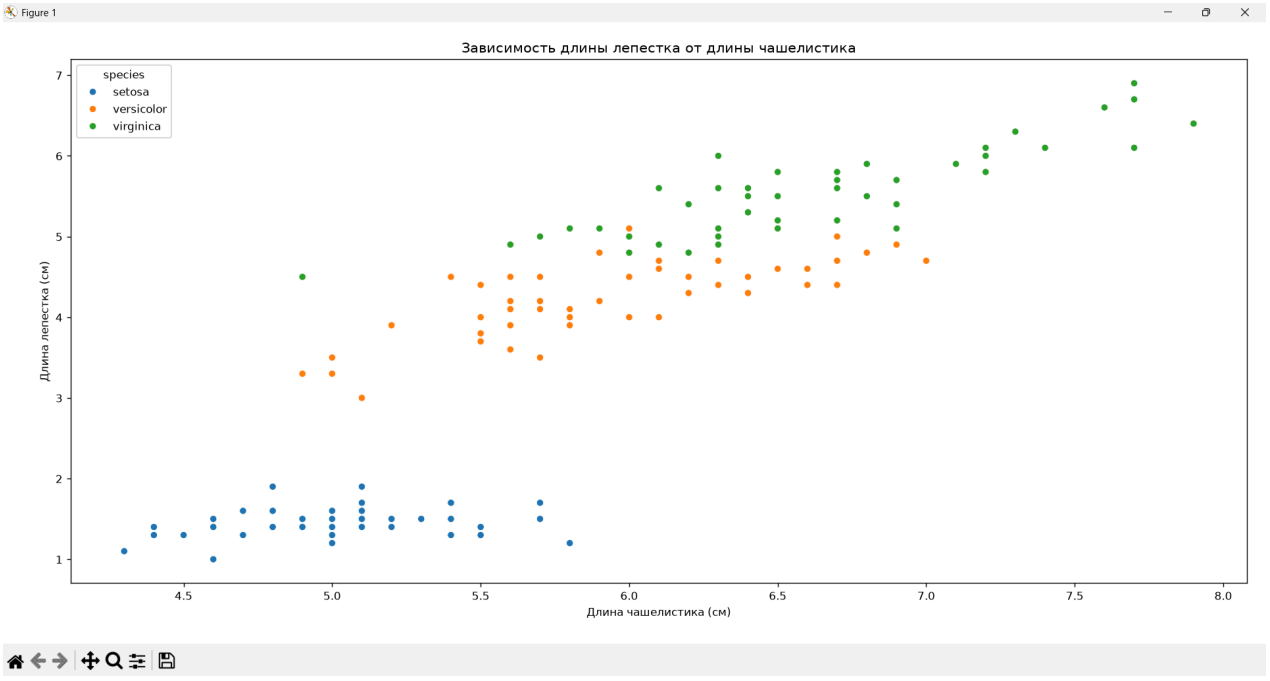


Рисунок 3 - Зависимость длины лепестка от длины чашелистика

На диаграмме показана зависимость длины лепестка от длины чашелистика. Точки разделены по видам ириса. Видно, что с увеличением длины чашелистика в целом увеличивается и длина лепестка. Также график показывает различия между видами ириса.

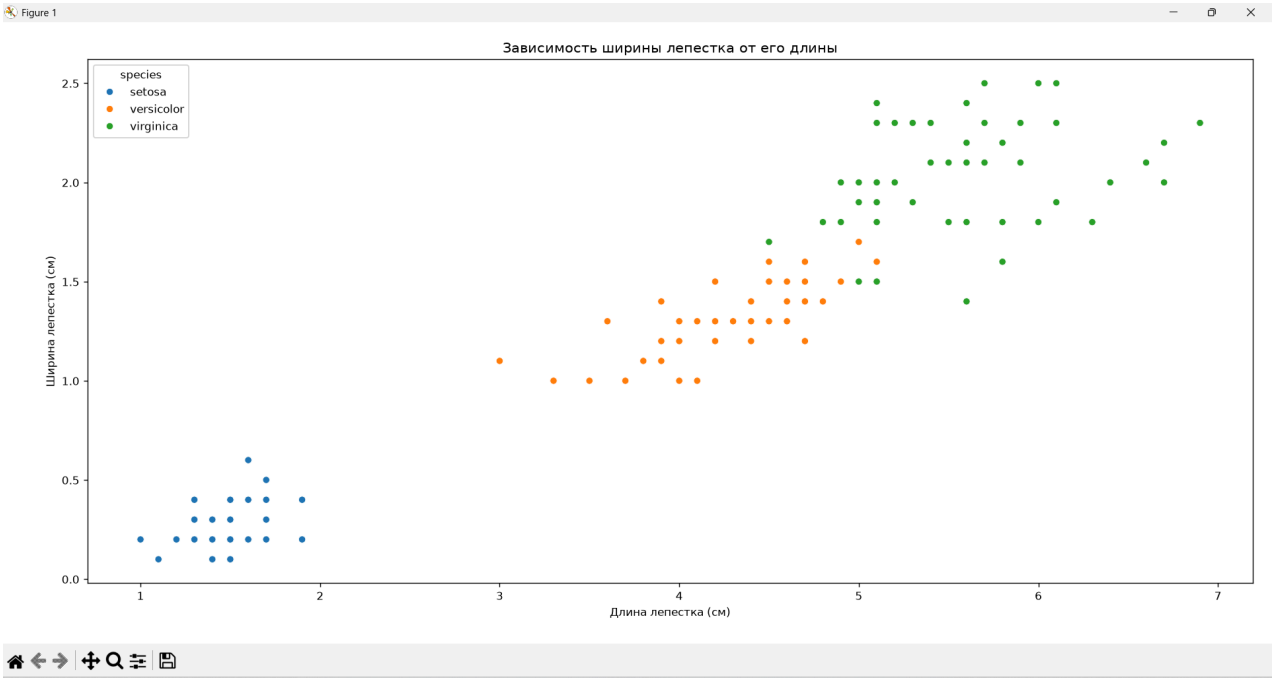


Рисунок 4 - Зависимость ширины лепестка от его длины

На диаграмме показана зависимость ширины лепестка от его длины для трех видов ириса. Видно, что между этими признаками существует выраженная зависимость. Объекты разных видов ириса образуют отдельные группы, особенно хорошо это заметно для вида setosa.

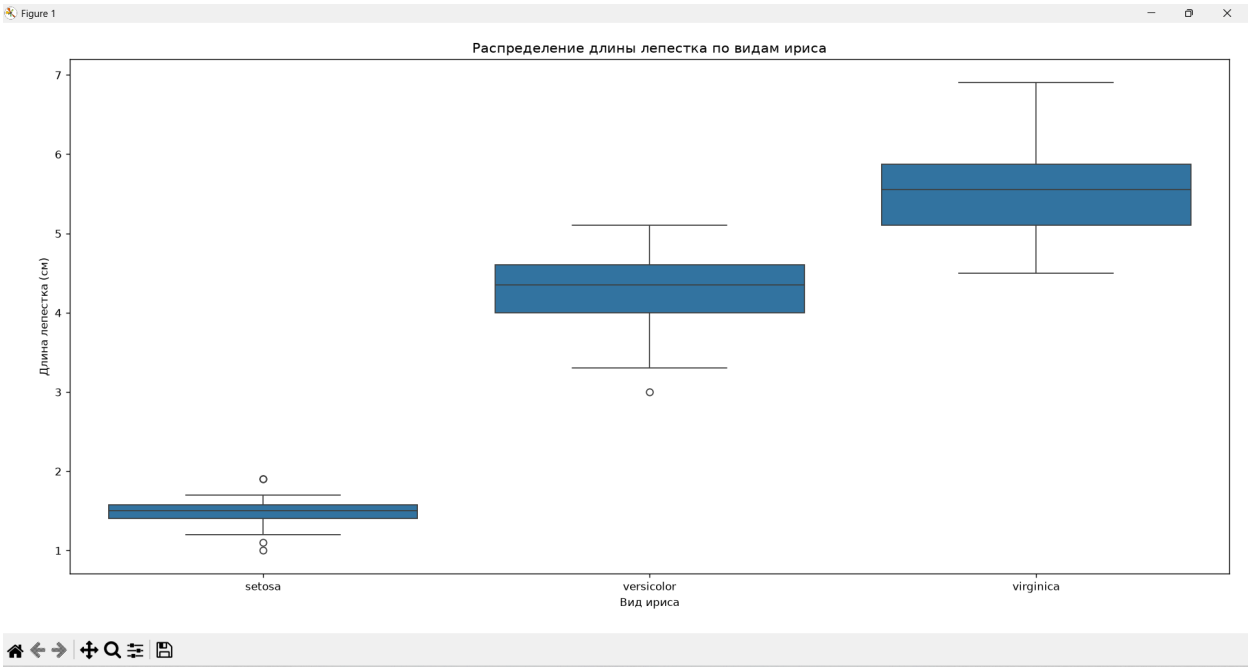


Рисунок 5 - Распределение длины лепестка по видам ириса

На диаграмме показано распределение длины лепестка для каждого вида ириса. Видно, что значения для разных видов отличаются. У вида setosa длина лепестка значительно меньше, чем у versicolor и virginica. Диаграмма также позволяет сравнить диапазон значений и медианы для каждого вида.

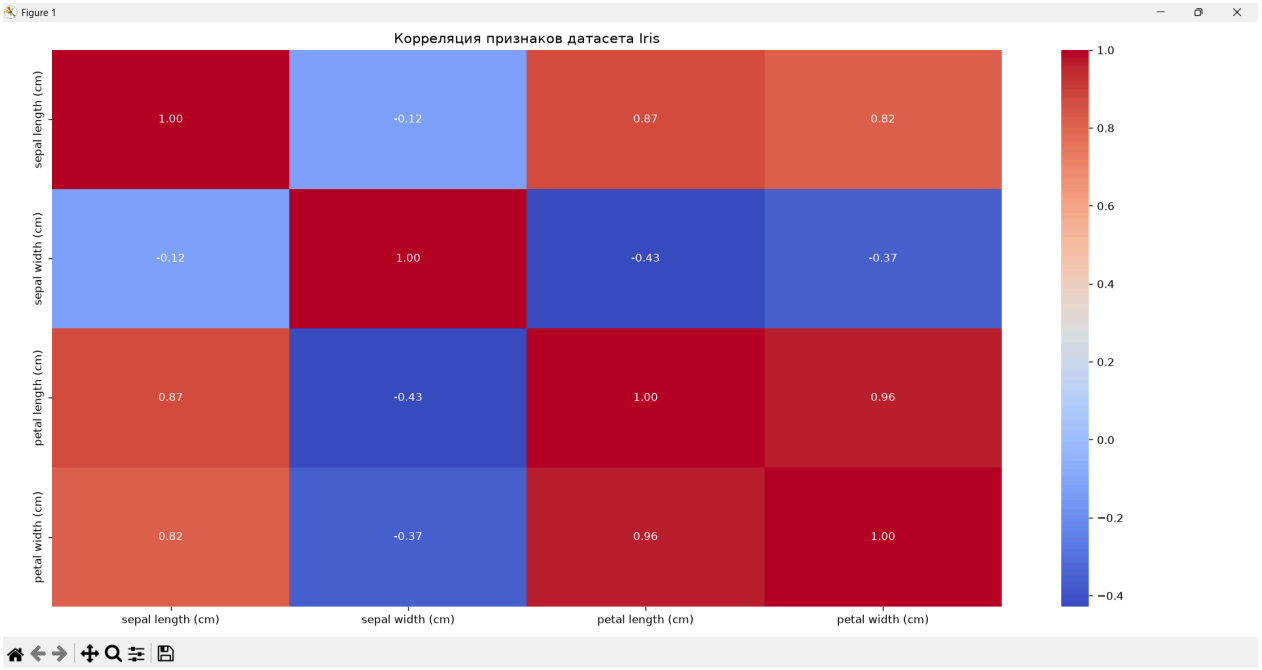


Рисунок 6 - Корреляционная матрица и тепловая карта признаков

Для исследования взаимосвязи между числовыми признаками была рассчитана корреляционная матрица и построена её тепловая карта. Корреляционная матрица позволяет определить направление и силу взаимосвязи между признаками, а тепловая карта представляет эти значения в наглядном графическом виде.

Наиболее сильная положительная взаимосвязь наблюдается между длиной и шириной лепестка. Также заметна положительная связь между длиной чашелистика и длиной лепестка.

4. Вывод

В ходе лабораторной работы был проведён разведочный анализ набора данных Iris с использованием Python. Были изучены структура и основные характеристики данных, проверено отсутствие пропущенных значений, а также построены различные виды графиков для визуального анализа признаков.

С помощью диаграмм было исследовано распределение признаков и различия между тремя видами ириса. Корреляционный анализ позволил определить взаимосвязи между числовыми признаками и представить их с помощью тепловой карты.

Таким образом, в ходе работы были изучены основные методы первичного анализа и визуализации данных.