

Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ **ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ**

КАФЕДРА **ИНФОРМАЦИОННЫЕ СИСТЕМЫ И ТЕЛЕКОММУНИКАЦИИ (ИУ3)**

НАПРАВЛЕНИЕ ПОДГОТОВКИ **09.03.03 ПРИКЛАДНАЯ ИНФОРМАТИКА**

ОТЧЕТ

по лабораторной работе № 6

Название: Ансамбли моделей машинного обучения. Часть 2

Дисциплина: Технологии машинного обучения

Студент ИУ3С-51Б _____ _____ М.Ю. Гордон
(Группа) (Подпись, дата) (И.О. Фамилия)

Преподаватель _____ О.Г. Саргсян
(Подпись, дата) (И.О. Фамилия)

Москва, 2026

1. Описание задания

Цель лабораторной работы — изучение ансамблей моделей машинного обучения.

- Выберите набор данных (датасет) для решения задачи классификации или регресии.
- В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
- С использованием метода train_test_split разделите выборку на обучающую и тестовую.
- Обучите следующие ансамблевые модели:
  - одну из моделей группы стекинга.
  - модель многослойного персептрона. По желанию, вместо библиотеки scikit-learn возможно использование библиотек TensorFlow, PyTorch или других аналогичных библиотек.
- Оцените качество моделей с помощью одной из подходящих для задачи метрик. Сравните качество полученных моделей.

Используется датасет Mushroom Dataset, содержащий информацию о грибах. Датасет включает 8124 записи и 23 столбца: 22 признака, описывающих характеристики грибов, и один целевой признак `class`, указывающий, является гриб съедобным (`e`) или ядовитым (`p`).

Признаки содержат информацию о форме, поверхности и цвете шляпки, запахе, характеристиках пластинок, ножки, кольца, спор и среде обитания гриба. Исходные данные являются категориальными, поэтому перед обучением моделей категориальные признаки преобразуются в числовой.

2. Текст программы по ноутбукам и их результаты

```
import pandas as pd
```

```
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder

# Загружаем датасет
df = pd.read_csv("mushrooms.csv")

# Разделяем признаки и целевую переменную
X = df.drop("class", axis=1)
y = df["class"]

# Кодируем категориальные признаки
X = pd.get_dummies(X, dtype=int)

# Кодируем целевую переменную
label_encoder = LabelEncoder()
y = label_encoder.fit_transform(y)

# Разделяем данные на обучающую и тестовую выборки
X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.2,
    random_state=42,
    stratify=y
)

# Выводим информацию о данных
print("Размер датасета:", df.shape)
print("Размер матрицы признаков:", X.shape)
print("Обучающая выборка:", X_train.shape)
print("Тестовая выборка:", X_test.shape)
print("Пропуски в датасете:", df.isnull().sum().sum())
print("Классы:", label_encoder.classes_)
```

```
Размер датасета: (8124, 23)
Размер матрицы признаков: (8124, 117)
Обучающая выборка: (6499, 117)
Тестовая выборка: (1625, 117)
Пропуски в датасете: 0
Классы: ['e' 'p']
```

Рисунок 1 - Информация о датасете

```
from sklearn.ensemble import RandomForestClassifier, ExtraTreesClassifier,
StackingClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score

# Создаём базовые модели и метамодель
stacking_model = StackingClassifier(
    estimators=[
        ("random_forest", RandomForestClassifier(
            n_estimators=100,
            random_state=42
        )),
```

```
        ("extra_trees", ExtraTreesClassifier(
            n_estimators=100,
            random_state=42
        ))
    ],
    final_estimator=LogisticRegression(max_iter=1000),
    cv=5
)

# Обучаем стекинг
stacking_model.fit(X_train, y_train)

# Получаем предсказания
y_pred_stacking = stacking_model.predict(X_test)

# Оцениваем качество
stacking_accuracy = accuracy_score(y_test, y_pred_stacking)

print("Точность модели Stacking:", round(stacking_accuracy, 4))
```

```
Точность модели Stacking: 1.0
```

Рисунок 2 - Точность модели “Стекинга”

```
from sklearn.neural_network import MLPClassifier
from sklearn.metrics import accuracy_score

# Создаём модель многослойного персептрона
mlp_model = MLPClassifier(
    hidden_layer_sizes=(100, 50),
    activation="relu",
    solver="adam",
    max_iter=300,
    random_state=42,
    early_stopping=True
)

# Обучаем модель на масштабированных данных
mlp_model.fit(X_train, y_train)

# Получаем предсказания
y_pred_mlp = mlp_model.predict(X_test)

# Оцениваем качество модели
mlp_accuracy = accuracy_score(y_test, y_pred_mlp)

print("Точность модели MLP:", round(mlp_accuracy, 4))
```

```
Точность модели MLP: 0.9982
```

Рисунок 3 - Точность модели “Многослойного персептрона”

```
import pandas as pd
```

```
# Формируем таблицу сравнения моделей
results_df = pd.DataFrame({
    "Модель": ["Stacking", "MLP"],
    "Accuracy": [stacking_accuracy, mlp_accuracy]
})

print("Сравнение моделей:")
print(results_df.round(4).to_string(index=False))
```

```
Сравнение моделей:
  Модель  Accuracy
Stacking    1.0000
     MLP    0.9982
```

Рисунок 4 - Сравнение моделей

3. Вывод

В ходе лабораторной работы были изучены и применены два метода машинного обучения: стекинг (Stacking) и многослойный персептрон (MLP).

Для обучения моделей был использован датасет грибов, содержащий информацию о съедобных и ядовитых грибах. Перед обучением данные были подготовлены и разделены на обучающую и тестовую выборки. По результатам оценки Stacking показал точность 100%, а MLP — 99,82%.

Таким образом, обе модели продемонстрировали высокое качество классификации, при этом лучший результат на тестовой выборке показал стекинг.